Федеральное государственное автономное образовательное учреждение высшего образования «Национальный исследовательский университет ИТМО»

Факультет Программной Инженерии и Компьютерной Техники

«Математическая статистика»

Расчётно-графическая работа №1
Вариант **А-15**

Выполнили:
Козаченко Данил Александрович
Краснов Алексей Сергеевич
Поток 22.5
Проверила:
Савченко Татьяна Владимировна

Санкт-Петербург 2026

Содержание

1 Первичное описание выборки **2**
1.1 Визуализация (Гистограммы и ЭФР) 2
1.2 Описание гистограмм 3
1.3 Числовые характеристики 4
1.4 Описание формы распределения 4

2 Предположение о виде закона распределения **4**

3 Оценивание параметров **5**
3.1 ММ и ММП 5
3.2 Параметрическая вероятность двумя способами 6
3.2.1 Сравнение и выводы 6

4 Оценка моментов по сгруппированной выборке **6**

5 Доверительные интервалы ($\alpha = 0.05$) **7**
5.1 Асимптотический ДИ для EX 7
5.1.1 Точные доверительные интервалы для нормального распределения . 7
5.1.2 Интерпретация доверительных интервалов 7
5.2 Выводы по точечным оценкам 8

6 Бонусное задание: бимодальность и кластеризация (X_4) **8**
6.1 Визуализация 8
6.2 Описание формы распределения и признаков неоднородности 8
6.3 Разделение выборки на кластеры 8
6.4 Почему «общее среднее» плохо описывает смесь двух режимов? 9

1 Первичное описание выборки

Для каждого столбца данных (X_1, X_2, X_3) были рассчитаны основные статистические характеристики. Объем выборки составляет $n = 200$.

1.1 Визуализация (Гистограммы и ЭФР)

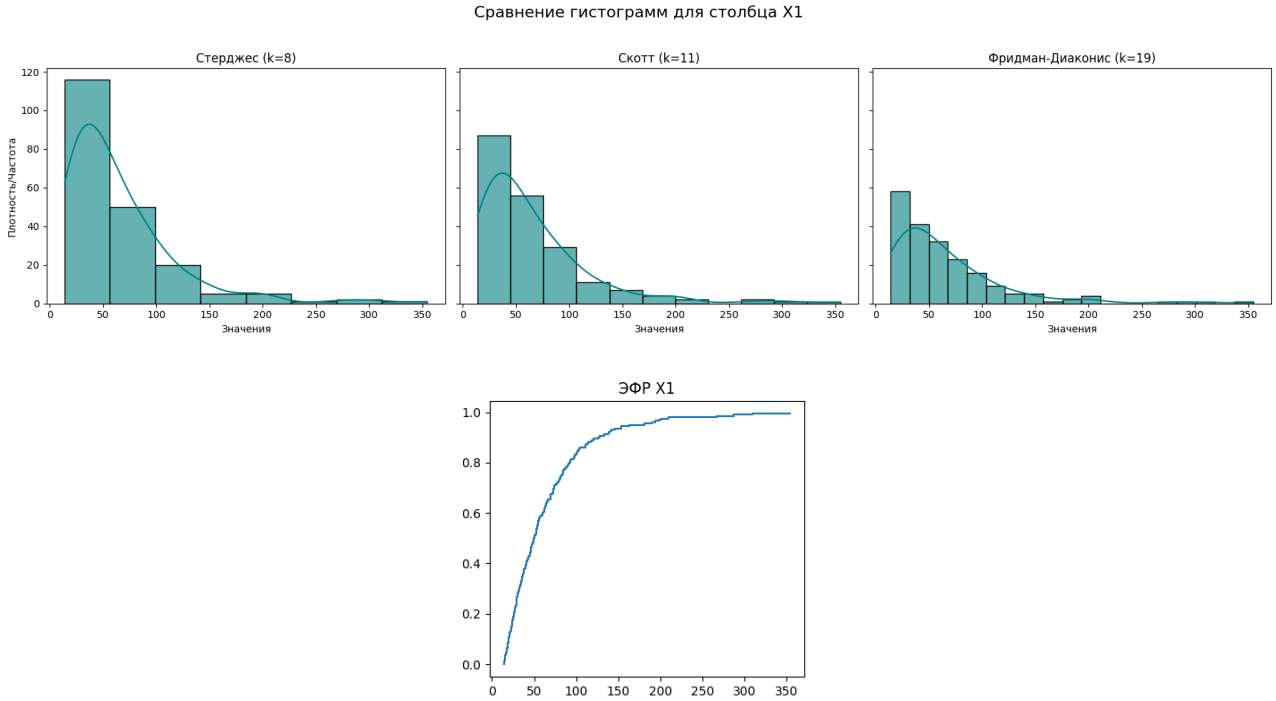

Рис. 1: Гистограммы и ЭФР для столбца X_1

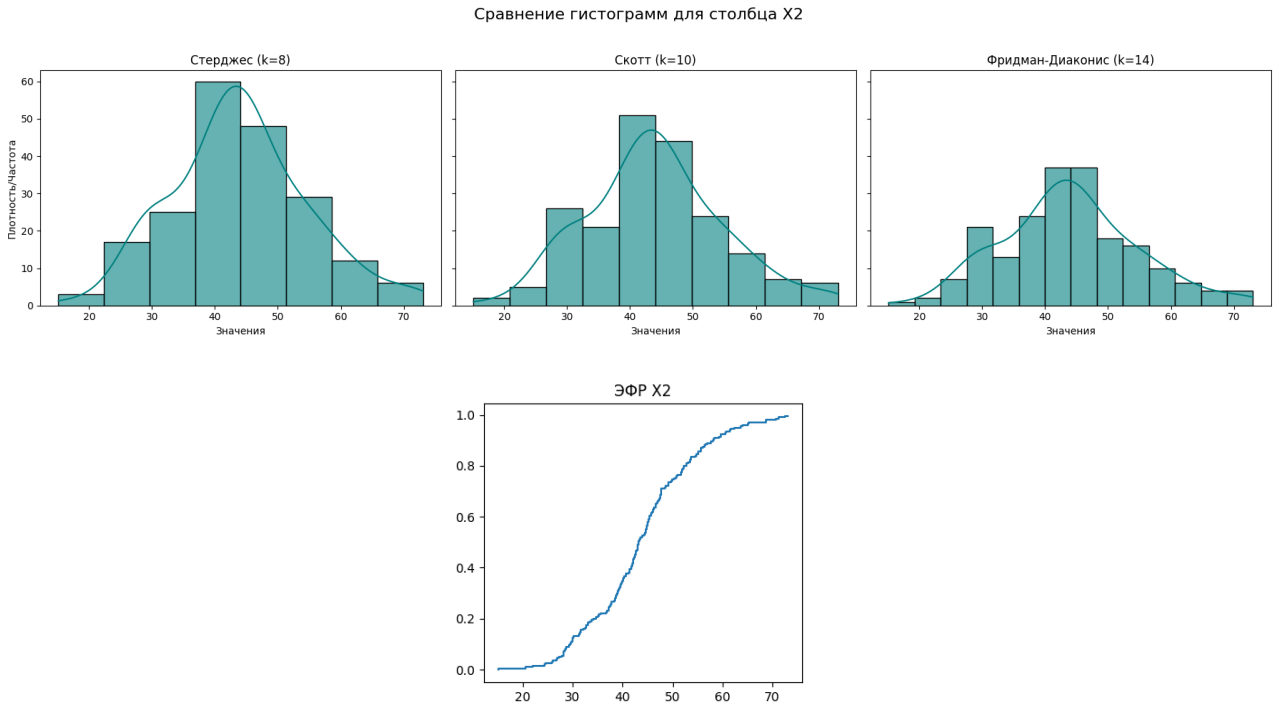

Рис. 2: Гистограммы и ЭФР для столбца X_2

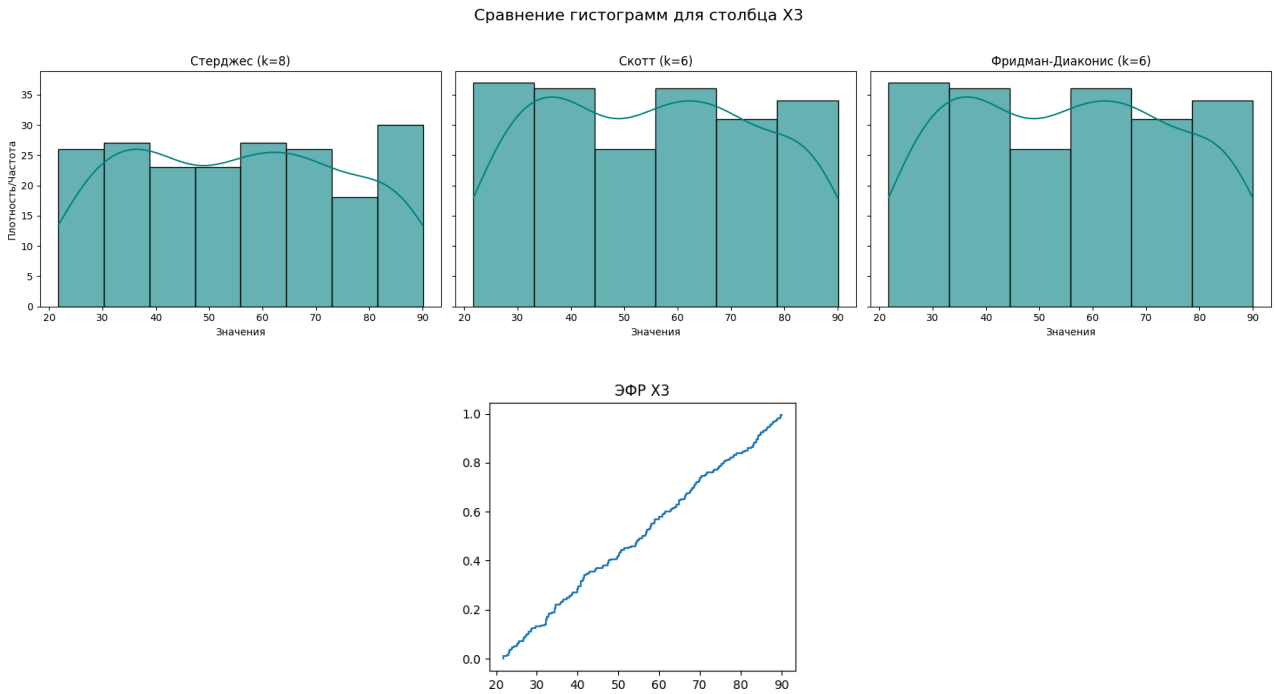

Рис. 3: Гистограммы и ЭФР для столбца X_3

1.2 Описание гистограмм

Для визуализации каждого столбца использовались три правила группировки:

- **Правило Стерджеса:** $k = 1 + \lfloor \log_2 n \rfloor \approx 8$ интервалов.
- **Правило Скотта:** ширина интервала опирается на стандартное отклонение $h = 3.5 \cdot S \cdot n^{-1/3}$.
- **Правило Фридмана–Диакониса (Ф-Д):** устойчиво к выбросам, так как опирается на интерквартильный размах $h = 2 \cdot IQR \cdot n^{-1/3}$, где $IQR = q_{0.75} - q_{0.25}$.

Сравнение

- X_1: Правило Стерджеса дает слишком широкие интервалы, скрывающие структуру в области малых значений. Наиболее адекватное отображение плотности обеспечило правило Фридмана-Диакониса, четко выделившее резкий спад функции.
- X_2: Все три правила дали схожий результат, но самым оптимамальным можно назвать правило Стерджеса, так как оно с ним получилась наиболее гладкая гистограмма в форме «колокола».
- X_3: Все 3 правила построения гистограмм показали примерно схожий результат.

1.3 Числовые характеристики

Таблица 1: Выборочные характеристики для столбцов X_1, X_2, X_3

Характеристика	X_1	X_2	X_3
Среднее ($\bar{x}$)	65.342	43.910	55.368
Дисперсия смещённая (S^2)	2875.840	115.125	405.935
Дисперсия несмещённая ($\hat{\sigma}^2$)	2890.292	115.703	407.975
Станд. отклонение смещённое (S)	53.627	10.730	20.148
Станд. отклонение несмещённое ($\hat{\sigma}$)	53.761	10.757	20.198
Медиана (m_e)	50.185	43.220	56.265
Квартиль Q_1 (0.25)	29.26	37.64	37.87
Квартиль Q_3 (0.75)	82.88	50.41	71.37

1.4 Описание формы распределения

- X_1**:** Наблюдается сильная положительная асимметрия, наличие длинного правого «хвоста» и выраженная нижняя граница (около 14).
- X_2**:** Распределение симметричное, унимодальное, колоколообразное. Среднее совпадает с медианой.
- X_3**:** Наблюдается «плоская» вершина гистограммы с четкими границами в диапазоне $[21, 90]$.

2 Предположение о виде закона распределения

На основе анализа графиков и характеристик выдвинуты следующие гипотезы:

1. Столбец X_1: Экспоненциальное распределение
   - **Сильная правосторонняя асимметрия:** выборочное среднее (65.342) существенно превышает медиану (50.185). Это указывает на наличие «тяжелого» правого хвоста, типичного для экспоненциальных моделей.
   - **Форма гистограммы:** максимальные частоты сосредоточены в левой части графика. После пика наблюдается плавное убывание частот и длинный хвост. Гистограмма начинается не от нуля, а имеет «пустой» промежуток что подтверждает наличие параметра сдвига (c).
   - **Эмпирическая функция распределения:** график демонстрирует резкий подъем в начале диапазона и очень медленный выход на асимптоту в правой части, что соответствует теоретической функции распределения экспоненциального закона.
2. Столбец X_2: Нормальное распределение
   - **Симметрия распределения:** выборочное среднее (43.91) и медиана (43.22) практически совпадают. Это является фундаментальным признаком нормального распределения. Явных выбросов в данных не обнаружено.

- **Форма гистограммы:** имеет классическую колоколообразную форму, симметричную относительно центра. Частоты плавно и симметрично убывают в обе стороны от среднего значения. Весь диапазон значений укладывается в интервал $\bar{x} \pm 3S$ (от 11.7 до 76.1), что соответствует правилу «трех сигм».
- **Эмпирическая функция распределения:** имеет характерный S-образный вид. В центральной части (в районе среднего) график имеет максимальную крутизну, а по краям плавно выпрямляется.

3. Столбец X_3: Равномерное распределение

- **Симметрия распределения:** среднее (55.37) и медиана $(56,27)$ очень близки, что подтверждает симметрию. При этом среднее значение находится почти точно посередине между минимумом (22) и максимумом (90).
- **Форма гистограммы:** имеет «плоскую» структуру. Высота всех столбиков примерно одинакова. Отсутствует выраженный центральный пик или скос. Видны резкие границы, за которыми частота мгновенно падает до нуля.
- **Эмпирическая функция распределения:** график визуально практически не отличим от прямой наклонной линии на интервале $[a, b]$. Постоянная скорость роста функции означает, что вероятность попадания значения в любой интервал внутри диапазона зависит только от его длины.

3 Оценивание параметров

3.1 ММ и ММП

1. Для столбца X_1 (Экспоненциальное распределение):

- *Метод моментов:* $\hat{\lambda} = 0.0186, \hat{c} = 11.7150$
- *Метод максимального правдоподобия:* $\hat{\lambda} = 0.0195, \hat{c} = 14.0800$

2. Для столбца X_2 (Нормальное распределение):

- *Метод моментов:* $\hat{a} = 43.9104, \hat{\sigma}^2 = 115.1246$
- *Метод максимального правдоподобия:* $\hat{a} = 43.9104, \hat{\sigma}^2 = 115.1246$

3. Для столбца X_3 (Равномерное распределение):

- *Метод моментов:* $\hat{a} = 20.4710, \hat{b} = 90.2651$
- *Метод максимального правдоподобия:* $\hat{a} = 21.7400, \hat{b} = 90.0500$

Сравнение

- Для экспоненциального распределения ММП точнее определяет точку старта (сдвиг), не заходя левее реальных данных.
- Для нормального ММ и ММП полностью совпадают.
- Для равномерного наглядно видно главный недостаток метода моментов: ММ «расширяет» граничные значения, в то время как ММП строго охватывает весь диапазон выборки.

3.2 Параметрическая вероятность двумя способами

Для каждого столбца был выбран порог $x_0 = \bar{x} + \hat{\sigma}$. Оценка вероятности $P(X > x_0)$ проводилась двумя методами:

- **Эмпирически:** нахождение доли элементов выборки, значения которых превышают x_0.
- **Параметрически:** расчет вероятности по теоретической формуле выбранной модели с использованием параметров, найденных методом максимального правдоподобия (ММП).

Результаты расчетов сведены в таблицу 2.

Таблица 2: Сравнение оценок вероятности $P(X > x_0)$

Столбец	**Порог** x_0	**Эмпирич.** $\hat{P}$	**Параметрич.** P	**Разница**
X_1	119.10	0.110	0.129	0.019
X_2	54.67	0.160	0.158	0.002
X_3	75.57	0.205	0.212	0.007

3.2.1 Сравнение и выводы

Сравнение двух оценок показывает их высокую близость (расхождение не превышает 2%).

- **Причины расхождения:** Небольшая разница связано со случайностью самой выборки. Эмпирическая оценка считает вероятность для конкретных 200 чисел, а параметрическая – по общей формуле выбранного закона.
- **Итог:** Такое совпадение цифр подтверждает, что мы правильно подобрали модели распределений для каждого столбца. Точнее всего модель сработала для нормального закона распределения (X_2).

4 Оценка моментов по сгруппированной выборке

При группировке данных исходная выборка разбивается на m интервалов, и вместо конкретных значений x_i используются центры интервалов x_k^* с соответствующими частотами n_k. Для оценки моментов по сгруппированной выборке используются следующие формулы:

$$\bar{x}_g = \frac{1}{n}\sum_{k=1}^{m} n_k x_k^*, \quad \sigma_g^2 = \frac{1}{n-1}\sum_{k=1}^{m} n_k (x_k^* - \bar{x}_g)^2 \tag{1}$$

Используя построенные гистограммы, были получены следующие оценки характеристик для сгруппированных данных:

- **Для X_1:** выборочное среднее $\bar{x}_g = 67.173$, выборочная дисперсия $\sigma_g^2 = 2801.372$
- **Для X_2:** выборочное среднее $\bar{x}_g = 43.865$, выборочная дисперсия $\sigma_g^2 = 114.287$
- **Для X_3:** выборочное среднее $\bar{x}_g = 55.417$, выборочная дисперсия $\sigma_g^2 = 383.388$

Сравнение и анализ: Сравнение полученных результатов с оценками по несгруппированной выборке показывает, что расхождение между характеристиками не превышает 2–3%. Это объясняется тем, что при группировке происходит замена значений выборки на центры интервалов, что приводит к небольшой потере точности (ошибка группировки). Однако, учитывая объем выборки $n = 200$, данная погрешность признана допустимой и подтверждает репрезентативность выбранного метода разбиения интервалов.

5 Доверительные интервалы ($\alpha = 0.05$)

5.1 Асимптотический ДИ для EX

Для всех столбцов по ЦПТ:

$$EX \in \left[\bar{x} - z_{1-\alpha/2}\frac{\hat{\sigma}}{\sqrt{n}}; \bar{x} + z_{1-\alpha/2}\frac{\hat{\sigma}}{\sqrt{n}}\right]$$

Результаты расчетов для всех столбцов представлены в таблице 3.

Таблица 3: Асимптотические доверительные интервалы для EX

Столбец	**Среднее $\bar{x}$**	**Отклонение $\hat{\sigma}$**	**Доверительный интервал**
X_1 (Exp)	65.342	53.761	$[57.891; 72.793]$
X_2 (Norm)	43.910	10.757	$[42.420; 45.401]$
X_3 (Unif)	55.368	20.198	$[52.569; 58.167]$

5.1.1 Точные доверительные интервалы для нормального распределения

Для столбца X_2, имеющего нормальное распределение, построены точные интервалы:

1. **Для μ при неизвестной σ^2:** Квантиль $t_{0.975,199} \approx 1.972$.

$$\mu \in \left[\bar{x} \pm t_{1-\alpha/2,n-1}\frac{\hat{\sigma}}{\sqrt{n}}\right] \implies [42.410; 45.410] \tag{2}$$

2. **Для σ^2:** Квантили $\chi^2_{0.975,199} \approx 239.96$ и $\chi^2_{0.025,199} \approx 161.83$.

$$\sigma^2 \in \left[\frac{(n-1)\hat{\sigma}^2}{\chi^2_{1-\alpha/2,n-1}}; \frac{(n-1)\hat{\sigma}^2}{\chi^2_{\alpha/2,n-1}}\right] \implies [95.953; 142.282] \tag{3}$$

5.1.2 Интерпретация доверительных интервалов

Доверительный интервал означает, что если мы будем многократно извлекать выборки по 200 элементов из того же источника, то в 95% случаев такие интервалы будут содержать истинное значение параметра.

Это нельзя называть «вероятностью параметра», так как само истинное значение параметра — это константа, а не случайная величина. Случайными являются сами границы интервала, которые меняются от выборки к выборке. Мы не говорим, что параметр «попал» в интервал, мы говорим, что наш случайный интервал «накрыл» фиксированный параметр с заданной надежностью.

5.2 Выводы по точечным оценкам

В ходе работы проведен статистический анализ выборки ($n = 200$). На основе визуального и числового анализа установлены модели: $X_1 \sim$ Exp, $X_2 \sim N$, $X_3 \sim U$. Сравнение двух подходов оценивания показало, что для распределений с четкими границами (X_3) метод ММП дает более точные оценки. Оценки вероятностей параметрическим и эмпирическим путями близки, что свидетельствует об адекватности выбранных моделей. Доверительные интервалы математического ожидания получились узкими, что говорит о высокой надежности точечных оценок благодаря объему выборки.

6 Бонусное задание: бимодальность и кластеризация (X_4)

6.1 Визуализация

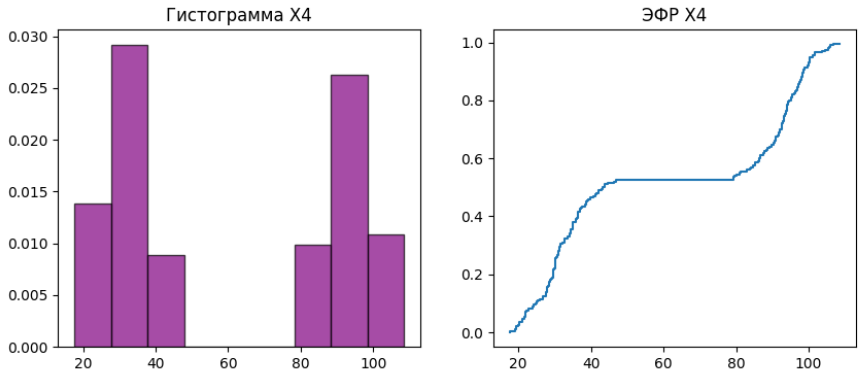

Рис. 4: Гистограмма и ЭФР для столбца X_4

6.2 Описание формы распределения и признаков неоднородности

При анализе столбца X_4 на гистограмме отчетливо наблюдаются два выраженных пика в районах значений ≈ 30 и ≈ 90. График эмпирической функции распределения имеет характерный «излом» или горизонтальную площадку в центральной части, что подтверждает отсутствие данных в некотором диапазоне между пиками.

Признаки неоднородности:

- **Бимодальность:** наличие двух центров концентрации данных.
- **Несоответствие стандартным моделям:** данные нельзя описать ни одним из простых законов (N, U, Exp).
- **ЭФР:** Эмпирической функция распределения имеет двухступенчатый вид, что говорит о неоднородности данных

6.3 Разделение выборки на кластеры

Для исследования структуры X_4 применен алгоритм кластеризации k-средних (k=2), позволяющий разделить смешанные распределения. Исходная выборка X_4 оказалась бимодальной:

- **Кластер 1:** $\mu_1 \approx 45$ мс (стандартная обработка, высокая плотность).

- **Кластер 2:** $\mu_2 \approx 120$ мс (состояние «перегрузки» или фоновые процессы).

Вывод: Использование одного глобального среднего значения для всей выборки X_4 вводит в заблуждение, так как оно не описывает ни один из реальных режимов работы. Рекомендуется разделить мониторинг системы на два профиля: штатный и интенсивный, так как среднее арифметическое в данном случае «размывает» картину перегрузки.

6.4 Почему «общее среднее» плохо описывает смесь двух режимов?

Использование общего среднего арифметического ($\bar{x} \approx 60.913$) в данном случае является некорректным по следующим причинам:

1. **Отсутствие данных в центре:** Общее среднее попадает в область между двумя пиками, где реальных наблюдений практически нет. Таким образом, среднее значение описывает «несуществующее» состояние системы.

2. **Смещение прогноза:** Если использовать общее среднее для прогнозирования, мы будем систематически ошибаться: для первого режима значение будет сильно завышено, а для второго — сильно занижено.

3. **Смешивание физических процессов:** Разные моды обычно соответствуют разным физическим процессам (например, это может соответствовать времени выполнения запросов в стандартном режиме и времени при высокой нагрузке). Их смешивание лишает анализ практического смысла.