

Федеральное государственное автономное образовательное учреждение высшего образования «Национальный исследовательский университет ИТМО»

Факультет Программной Инженерии и Компьютерной Техники

«Математическая статистика»

Расчётно-графическая работа №3
Вариант **A-15**

Выполнили:

Козаченко Данил Александрович

Краснов Алексей Сергеевич

Поток 22.5

Проверила:

Савченко Татьяна Владимировна

Санкт-Петербург 2026

Содержание

1	Исходные данные	2
1.1	Таблица исходных данных	2
2	Первичный анализ данных. Диаграмма рассеяния	3
3	Построение регрессионных моделей	3
3.1	Линейная модель	3
3.2	Квадратичная модель	4
3.3	Степенная модель	4
4	Сравнение моделей	5
5	Подробный статистический анализ линейной модели	6
5.1	Прогнозные значения и остатки	6
5.2	Остаточная сумма квадратов RSS	6
5.3	Несмещённая оценка дисперсии ошибки	6
5.4	Стандартные ошибки коэффициентов	6
5.5	Доверительные интервалы (95%)	7
5.6	Проверка гипотезы о значимости наклона	7
6	Прогноз при $x^* = 494.1171$ МБ/с	7
7	Итоговый вывод	7

1 Исходные данные

$n = 24$.

Набор данных: `openintro::ssd_speed` — «SSD read and write speeds» (пакет `openintro` для языка R, репозиторий Rdatasets).

Страница-источник: https://vincentarelbundock.github.io/Rdatasets/doc/openintro/ssd_speed.html

Получение среза: из полного набора `ssd_speed` отобраны строки, для которых `nvme == 0` — накопители без интерфейса NVMe. NVMe- и SATA-накопители работают в разных скоростных диапазонах, поэтому смешивать их в одной модели не имеет смысла.

Переменные:

- x — скорость последовательного чтения, МБ/с (`read`);
- y — скорость последовательной записи, МБ/с (`write`).

Сравниваемые модели: линейная, квадратичная, степенная ($y = ax^b$).

Прогнозное значение: $x^* = 494,1171$ МБ/с (107% от среднего $\bar{x} = 461,7917$).

1.1 Таблица исходных данных

Таблица 1: Скорость чтения и записи для non-NVMe SSD

i	x , МБ/с	y , МБ/с	i	x , МБ/с	y , МБ/с
1	376	361	13	470	389
2	408	419	14	471	433
3	442	385	15	472	394
4	443	381	16	474	401
5	445	389	17	476	418
6	448	390	18	477	424
7	456	418	19	478	400
8	459	420	20	481	437
9	463	428	21	483	405
10	465	407	22	484	425
11	469	359	23	485	444
12	470	391	24	488	380

2 Первичный анализ данных. Диаграмма рассеяния




Рис. 1: Диаграмма рассеяния

Гипотеза о характере связи. На диаграмме рассеяния точки расположены с большим разбросом, явной зависимости не видно. Формально прослеживается слабая положительная тенденция: при росте скорости чтения скорость записи в среднем немного растёт, однако уверенно говорить о наличии связи по графику затруднительно.

3 Построение регрессионных моделей

3.1 Линейная модель

Модель: $y = a + bx$.

Оценки МНК:

$$\bar{x} = 461.7917, \quad \bar{y} = 404.0833,$$

$$S_{xx} = \sum (x_i - \bar{x})^2 = 15281.9583, \quad S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) = 5481.4167,$$

$$b = \frac{S_{xy}}{S_{xx}} = \frac{5481.4167}{15281.9583} = 0.3587, \quad a = \bar{y} - b\bar{x} = 404.0833 - 0.3587 \cdot 461.7917 = 238.4454.$$

$$\boxed{y = 238.4454 + 0.3587x}$$

3.2 Квадратичная модель

Модель: $y = a + bx + cx^2$.

Параметры найдены методом наименьших квадратов:

$$a = 225.8933, \quad b = 0.4164, \quad c = -0.0001.$$

$$y = -0.0001x^2 + 0.4164x + 225.8933$$

Коэффициент при x^2 близок к нулю, что уже указывает на то, что реальная модель данных больше близка к линейной, чем к квадратичной

3.3 Степенная модель

Модель: $y = ax^b$.

Приведём к линейному виду: $\ln y = \ln a + b \ln x$.

Применяем МНК к преобразованным данным ($X = \ln x, Y = \ln y$):

$$\bar{X} = 6.1335, \quad \bar{Y} = 6.0001,$$

$$S_{XX} = \sum (X_i - \bar{X})^2 = 0.0806, \quad S_{XY} = \sum (X_i - \bar{X})(Y_i - \bar{Y}) = 0.0319,$$

$$b = \frac{S_{XY}}{S_{XX}} = \frac{0.0806}{0.0319} = 0.3953, \quad a = \bar{Y} - b\bar{X} = 6.0001 - 0.3953 \cdot 6.1335 = 35.7132$$

$$y = 35.7132 \cdot x^{0.3953}$$

4 Сравнение моделей




Рис. 2: Графики остатков и самих функций

Таблица 2: Показатели качества трёх моделей

Модель	R^2	A (Средняя ошибка аппроксимации), %
Линейная ($y = a + bx$)	0.1624	4.3866
Квадратичная ($y = a + bx + cx^2$)	0.1624	4.3865
Степенная ($y = ax^b$)	0.1619	4.3699

Вывод. Все три модели демонстрируют практически одинаковое качество аппроксимации. Коэффициент детерминации $R^2 \approx 0.162$ для всех моделей означает, что аппроксимирующие функции практически никак не описывают наши данные.

Квадратичная модель не даёт ощутимого выигрыша (коэффициент при x^2 практически нулевой). Степенная модель тоже не описывает данные. Визуально все три кривые практически совпадают в исследуемом диапазоне.

Предпочтительная модель: линейная - как наиболее простая при равно плохих других аппроксимирующих функциях.

Характер остатков у всех трёх моделей схож: точки расположены без явного тренда относительно нулевой линии, что свидетельствует об отсутствии систематической составляющей ошибки.

5 Подробный статистический анализ линейной модели

5.1 Прогнозные значения и остатки

Таблица 3: Остатки линейной модели $\hat{y} = 238.4454 + 0.3587x$

i	x_i	y_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$
1	376	361	373.311	-12.311
2	408	419	384.789	34.211
3	442	385	396.984	-11.984
4	443	381	397.343	-16.343
5	445	389	398.060	-9.060
6	448	390	399.137	-9.137
7	456	418	402.006	15.994
8	459	420	403.082	16.918
9	463	428	404.517	23.483
10	465	407	405.234	1.766
11	469	359	406.669	-47.669
12	470	391	407.028	-16.028
13	470	389	407.028	-18.028
14	471	433	407.386	25.614
15	472	394	407.745	-13.745
16	474	401	408.462	-7.462
17	476	418	409.180	8.820
18	477	424	409.538	14.462
19	478	400	409.897	-9.897
20	481	437	410.973	26.027
21	483	405	411.691	-6.691
22	484	425	412.049	12.951
23	485	444	412.408	31.592
24	488	380	413.484	-33.484

5.2 Остаточная сумма квадратов RSS

$$\text{RSS} = \sum_{i=1}^{24} e_i^2 = 10143.73$$

5.3 Несмещённая оценка дисперсии ошибки

$$s^2 = \frac{\text{RSS}}{n-2} = \frac{10143.73}{22} = 461.08, \quad s = \sqrt{s^2} = 21.47$$

5.4 Стандартные ошибки коэффициентов

$$\text{SE}(b) = \frac{s}{\sqrt{S_{xx}}} = \frac{21.47}{\sqrt{15281.9583}} = 0.1737$$

$$\text{SE}(a) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} = 21.47 \sqrt{\frac{1}{24} + \frac{461.79^2}{15281.9583}} = 80.33$$

5.5 Доверительные интервалы (95%)

Квантиль Стьюдента: $t_{0.975;22} = 2.0739$.

$$\hat{b} \pm tSE(\hat{b}) = 0.3587 \pm 2.0739 \cdot 0.1737 = [-0.0015; 0.7189],$$

$$\hat{a} \pm tSE(\hat{a}) = 238.4454 \pm 2.0739 \cdot 80.33 = [71.85; 405.04].$$

5.6 Проверка гипотезы о значимости наклона

Рассматриваются гипотезы $H_0 : b = 0$ против $H_1 : b \neq 0$.

Наблюдаемое значение статистики Стьюдента:

$$t_{\text{набл}} = \frac{b}{SE(b)} = \frac{0.3587}{0.1737} = 2.065.$$

Критическое значение при $\alpha = 0.05$: $t_{\text{крит}} = 2.0739$.

Так как $|t_{\text{набл}}| = 2.065 < t_{\text{крит}} = 2.074$, гипотеза H_0 **не отвергается** на уровне значимости $\alpha = 0.05$.

Более простым путем: доверительный интервал для b содержит ноль $[-0.0015; 0.7189]$, что подтверждает тот же вывод.

Интерпретация: линейная зависимость между скоростью чтения и скоростью записи статистически незначима. Это объясняется значительным разбросом данных и небольшим объёмом выборки.

6 Прогноз при $x^* = 494.1171$ МБ/с

Таблица 4: Прогнозные значения скорости записи при $x^* = 494.1171$ МБ/с

Модель	$\hat{y}(x^*)$, МБ/с
Линейная	415.68
Квадратичная	415.55
Степенная	414.65

Выбранная модель для прогноза: линейная.

Прогноз по линейной модели: $\hat{y}(494.12) \approx 415.68$ МБ/с.

Все три модели дают почти одинаковый результат — расхождение меньше 1 МБ/с. Значение x^* лишь немного выходит за правую границу выборки ($x_{\text{max}} = 488$ МБ/с), так что экстраполяция минимальна.

При скорости чтения около 494 МБ/с модель предсказывает скорость записи порядка 415–416 МБ/с.

7 Итоговый вывод

В работе использовался набор данных `openintro::ssd_speed`. Изучалась зависимость скорости записи от скорости чтения для non-NVMe SSD (срез `nvme == 0`, $n = 24$).

Связь положительная, но очень слабая — $b = 0,3587$.

Были построены три модели: линейная, квадратичная и степенная. Все три показали одинаковое качество аппроксимации, поэтому в качестве предпочтительной выбрана линейная как наиболее простая: $\hat{y} = 238,45 + 0,3587 x$.

Связь между переменными слабая: $R^2 \approx 0,16$ означает, что построенные модели практически не описывают данные. Выборка маленькая ($n = 24$), разброс большой — по таким данным надёжную регрессионную модель построить затруднительно.

Прогноз при $x^* = 494,12$ МБ/с составляет $\hat{y} \approx 415,68$ МБ/с.