

# РГР 3

Вариант А-15


Выполнили:  
Козаченко Данил  
Краснов Алексей

(Поток 22.5)

# Первичный анализ данных. Диаграмма рассеяния

Таблица 1: Скорость чтения и записи для pop-NVMe SSD


| $i$ | $x$ , МБ/с | $y$ , МБ/с | $i$ | $x$ , МБ/с | $y$ , МБ/с |
|-----|------------|------------|-----|------------|------------|
| 1   | 376        | 361        | 13  | 470        | 389        |
| 2   | 408        | 419        | 14  | 471        | 433        |
| 3   | 442        | 385        | 15  | 472        | 394        |
| 4   | 443        | 381        | 16  | 474        | 401        |
| 5   | 445        | 389        | 17  | 476        | 418        |
| 6   | 448        | 390        | 18  | 477        | 424        |
| 7   | 456        | 418        | 19  | 478        | 400        |
| 8   | 459        | 420        | 20  | 481        | 437        |
| 9   | 463        | 428        | 21  | 483        | 405        |
| 10  | 465        | 407        | 22  | 484        | 425        |
| 11  | 469        | 359        | 23  | 485        | 444        |
| 12  | 470        | 391        | 24  | 488        | 380        |



- $x$  — скорость последовательного чтения, МБ/с (read);
- $y$  — скорость последовательной записи, МБ/с (write).

**Сравниваемые модели:** линейная, квадратичная, степенная ( $y = ax^b$ ).

**Прогнозное значение:**  $x^* = 494,1171$  МБ/с (107% от среднего  $\bar{x} = 461,7917$ ).



### 3.1 Линейная модель

Модель:  $y = a + bx$ .

Оценки МНК:


$$\bar{x} = 461.7917, \quad \bar{y} = 404.0833,$$

$$S_{xx} = \sum (x_i - \bar{x})^2 = 15281.9583, \quad S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) = 5481.4167,$$

$$b = \frac{S_{xy}}{S_{xx}} = \frac{5481.4167}{15281.9583} = 0.3587, \quad a = \bar{y} - b\bar{x} = 404.0833 - 0.3587 \cdot 461.7917 = 238.4454.$$

$$y = 238.4454 + 0.3587x$$

Таблица 3: Остатки линейной модели  $\hat{y} = 238.4454 + 0.3587x$



| $i$ | $x_i$ | $y_i$ | $\hat{y}_i$ | $e_i = y_i - \hat{y}_i$ |
|-----|-------|-------|-------------|-------------------------|
| 1   | 376   | 361   | 373.311     | -12.311                 |
| 2   | 408   | 419   | 384.789     | 34.211                  |
| 3   | 442   | 385   | 396.984     | -11.984                 |
| 4   | 443   | 381   | 397.343     | -16.343                 |
| 5   | 445   | 389   | 398.060     | -9.060                  |
| 6   | 448   | 390   | 399.137     | -9.137                  |
| 7   | 456   | 418   | 402.006     | 15.994                  |
| 8   | 459   | 420   | 403.082     | 16.918                  |
| 9   | 463   | 428   | 404.517     | 23.483                  |
| 10  | 465   | 407   | 405.234     | 1.766                   |

## 5.2 Остаточная сумма квадратов RSS

$$\text{RSS} = \sum_{i=1}^{24} e_i^2 = 10143.73$$

## 5.3 Несмещённая оценка дисперсии ошибки

$$s^2 = \frac{\text{RSS}}{n-2} = \frac{10143.73}{22} = 461.08, \quad s = \sqrt{s^2} = 21.47$$

## 5.4 Стандартные ошибки коэффициентов

$$\begin{aligned} \text{SE}(b) &= \frac{s}{\sqrt{S_{xx}}} = \frac{21.47}{\sqrt{15281.9583}} = 0.1737 \\ \text{SE}(a) &= s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} = 21.47 \sqrt{\frac{1}{24} + \frac{461.79^2}{15281.9583}} = 80.33 \end{aligned}$$

## 5.5 Доверительные интервалы (95%)

Квантиль Стьюдента:  $t_{0.975;22} = 2.0739$ .

$$\hat{b} \pm t\text{SE}(\hat{b}) = 0.3587 \pm 2.0739 \cdot 0.1737 = [-0.0015; 0.7189],$$

$$\hat{a} \pm t\text{SE}(\hat{a}) = 238.4454 \pm 2.0739 \cdot 80.33 = [71.85; 405.04].$$

## 5.6 Проверка гипотезы о значимости наклона

Рассматриваются гипотезы  $H_0 : b = 0$  против  $H_1 : b \neq 0$ .


Наблюдаемое значение статистики Стьюдента:

$$t_{\text{набл}} = \frac{b}{\text{SE}(b)} = \frac{0.3587}{0.1737} = 2.065.$$

Критическое значение при  $\alpha = 0.05$ :  $t_{\text{крит}} = 2.0739$ .

Так как  $|t_{\text{набл}}| = 2.065 < t_{\text{крит}} = 2.074$ , гипотеза  $H_0$  не отвергается на уровне значимости  $\alpha = 0.05$ .

Остатки квадратичной модели



## 3.2 Квадратичная модель

Модель:  $y = a + bx + cx^2$ .


Параметры найдены методом наименьших квадратов:


$$a = 225.8933, \quad b = 0.4164, \quad c = -0.0001.$$

$$y = -0.0001x^2 + 0.4164x + 225.8933$$

Коэффициент при  $x^2$  близок к нулю, что уже указывает на то, что реальная модель данных больше близка к линейной, чем к квадратичной

Диаграмма рассеяния и модели





### 3.3 Степенная модель

Модель:  $y = ax^b$ .

Приведём к линейному виду:  $\ln y = \ln a + b \ln x$ .

Применяем МНК к преобразованным данным ( $X = \ln x, Y = \ln y$ ):

$$\bar{X} = 6.1335, \quad \bar{Y} = 6.0001,$$

$$S_{XX} = \sum (X_i - \bar{X})^2 = 0.0806, \quad S_{XY} = \sum (X_i - \bar{X})(Y_i - \bar{Y}) = 0.0319,$$

$$b = \frac{S_{XY}}{S_{XX}} = \frac{0.0806}{0.0319} = 0.3953, \quad a = \bar{Y} - b\bar{X} = 6.0001 - 0.3953 \cdot 6.1335 = 35.7132$$

$$y = 35.7132 \cdot x^{0.3953}$$





Диаграмма рассеяния и модели



## 4 Сравнение моделей

Таблица 2: Показатели качества трёх моделей

| Модель                               | $R^2$  | A (Средняя ошибка аппроксимации), % |
|--------------------------------------|--------|-------------------------------------|
| Линейная ( $y = a + bx$ )            | 0.1624 | 4.3866                              |
| Квадратичная ( $y = a + bx + cx^2$ ) | 0.1624 | 4.3865                              |
| Степенная ( $y = ax^b$ )             | 0.1624 | 4.3865                              |

**Вывод.** Все три модели демонстрируют практически одинаковое качество аппроксимации. Коэффициент детерминации  $R^2 \approx 0.162$  для всех моделей означает, что аппроксимирующие функции практически никак не описывают наши данные.

## Прогноз при $x^* = 494.1171$ МБ/с

Таблица 4: Прогнозные значения скорости записи при  $x^* = 494.1171$  МБ/с

| Модель       | $\hat{y}(x^*)$ , МБ/с |
|--------------|-----------------------|
| Линейная     | 415.68                |
| Квадратичная | 415.55                |
| Степенная    | 414.65                |

**Выбранная модель для прогноза: линейная.**

Прогноз по линейной модели:  $\hat{y}(494.12) \approx 415.68$  МБ/с.

При скорости чтения около 494 МБ/с модель предсказывает скорость записи порядка 415–416 МБ/с.

## Итоговый вывод

В работе использовался набор данных `openintro::ssd_speed`. Изучалась зависимость скорости записи от скорости чтения для non-NVMe SSD (срез `nvme == 0`,  $n = 24$ ).

Связь положительная, но очень слабая —  $b = 0,3587$ .

Были построены три модели: линейная, квадратичная и степенная. Все три показали одинаковое качество аппроксимации, поэтому в качестве предпочтительной выбрана линейная как наиболее простая:  $\hat{y} = 238,45 + 0,3587 x$ .

Связь между переменными слабая:  $R^2 \approx 0,16$  означает, что построенные модели практически не описывают данные. Выборка маленькая ( $n = 24$ ), разброс большой — по таким данным надёжную регрессионную модель построить затруднительно.

Прогноз при  $x^* = 494,12$  МБ/с составляет  $\hat{y} \approx 415,68$  МБ/с.