Глава 14

Модели логистической регрессии

В модели линейной регрессии $X\beta + \varepsilon$ существует два типа переменных – объясняющие переменные $X_1, X_2, .., X_k$ и исследуемая переменная y. Эти переменные могут быть измерены по непрерывной шкале, а также как индикаторная переменная. Когда объясняющие переменные являются качественными, тогда их значения expressed как индикаторные переменные, и затем используются модели фиктивных переменных.

При исследовании переменная в качественной переменной, то ее значения могут быть выражены с помощью индикатора переменная принимает только два возможных значения 0 и 1. В таком случае используется логистическая регрессия. Например, y can обозначает такие значения, как успех или неудача, да или нет, нравится или не нравится, которые могут быть обозначены двумя значениями 0 и 1.

Рассмотрим модель

$$\begin{aligned} y_i &= \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + ... + \beta_k x_{ik} + \varepsilon_i \\ &= x_i'\beta + \varepsilon_i, \ i = 1, 2, ..., n \end{aligned}$$

где $x_i' = [1, x_{i1}, x_{i2}, ..., x_{ik}], \ \beta' = [\beta_0, \beta_1, \beta_2, ..., \beta_k]$.

Переменная исследования принимает два значения как $y_i = 0$ или 1. Предположим, что y_i следует распределению Бернулли с a parameter π_i, so its probability distribution is

$$y_i = \begin{cases} 1 & \text{with } P(y_i = 1) = \pi_i \\ 0 & \text{with } P(y_i = 0) = 1 - \pi_i. \end{cases}$$

Предполагая $E(\varepsilon_i) = 0,$

$$E(y_i) = 1.\pi_i + 0.(1 - \pi_i) = \pi_i.$$

Из модели $y_i = x_i'\beta + \varepsilon_i,$ мы имеем

$$E(y_i) = x_i'\beta$$
$$\Rightarrow E(y_i) = x_i'\beta = \pi_i$$
$$\Rightarrow E(y_i) = P(y_i = 1).$$

Таким образом, функция $E(y_i)$ - это просто вероятность того, что $y_i = 1.$

Обратите внимание , что $\varepsilon_i = y_i - x_i'\beta,$ поэтому

- когда $y_i = 1,$ then $\varepsilon_i = 1 - x_i'\beta$
- $y_i = 0,$ then $\varepsilon_i = -x_i'\beta.$

Напомним, что ранее ε_i was assumed to follow a normal distribution when y не было индикаторной переменной.

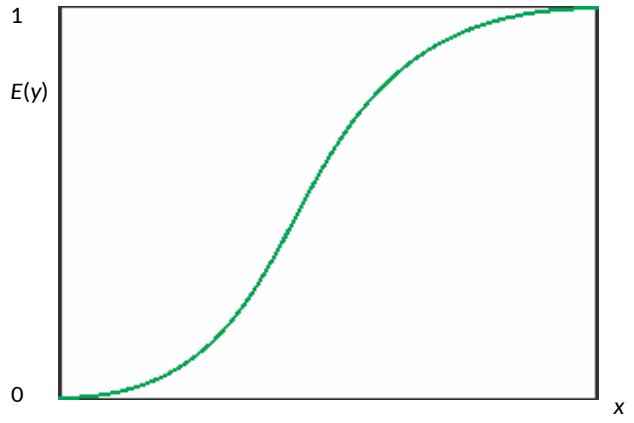
Когда y является индикаторной переменной, то ε_i принимает только два значения, поэтому нельзя предполагать, что она соответствует нормальному распределению.

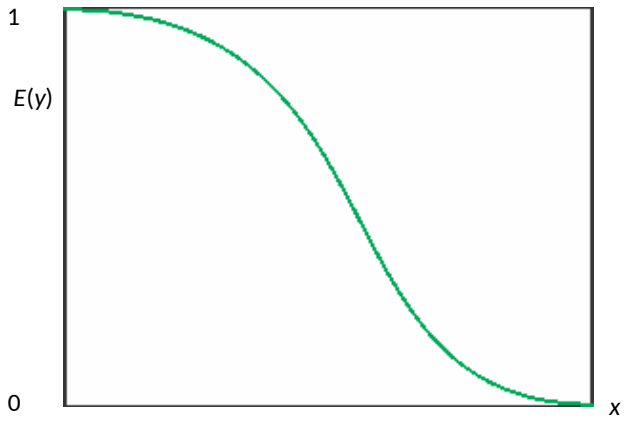
В обычной регрессионной модели ошибки гомоскедастичны, т.е. $Var(\varepsilon_i) = \sigma^2$ и так $Var(y_i) = \sigma^2$. Когда y является индикаторной переменной, тогда

$$\begin{aligned} Var(y_i) &= E\left[y_i - E(y_i)\right]^2 \\ &= (1 - \pi_i)^2\pi_i + (0 - \pi_i)^2(1 - \pi_i) \\ &= \pi_i(1 - \pi_i)\left[1 - \pi_i + \pi_i\right] \\ &= \pi_i(1 - \pi_i) \\ &= E(y_i)\left[1 - E(y_i)\right] \\ &= \sigma_{y_i}^2 . \end{aligned}$$

Таким образом $Var(y_i)$ depends on y_i and is a function mean of y_i. В Более того, поскольку $E(y_i) = \pi_i$ и π_i is the вероятностью, поэтому $0 \le \pi_i \le 1$ и, следовательно, существует ограничение on $E(y_i)$ $0 \le E(y_i) \le 1.$ что накладываетbig constraint on the choice of the linear функции отклика. Невозможно соответствовать модели in, в которой прогнозируемые значения лежат за пределами интервала 0 и 1.

Когда y является дихотомической переменной, то эмпирические данные свидетельствуют о том, что функция $E(y)$ на всей реальной прямой, которую можно отобразить на $[0,1]$ имеет сигмовидную форму. Это нелинейная S- форма , подобная





Естественным выбором для $E(y)$ была бы кумулятивная функция распределения случайной величины. В частности, логистическое распределение, чья кумулятивная распределения является упрощенной logistic function yields a good link and is given by

$$\begin{aligned} E(y) &= \frac{\exp(y)}{1+\exp(y)} \\ &= \frac{\exp(x'\beta)}{1+\exp(x'\beta)} \\ &= \frac{1}{1+\exp(-x'\beta)}. \end{aligned}$$

Линейный предиктор и функции связи:

Систематический компонент в $E(y)$ является линейным предиктором и обозначается как

$$\eta_i = \sum_j \beta_j x_{ij} = x_i'\beta, \; i = 1,2,...,n, \; j = 0,1,2,...,k.$$

Функция связи in обобщенной линейной модели связывает линейный предиктор η_i со средним откликом μ_i.

Таким образом

$$g(\mu_i) = \eta_i$$
$$\text{or } \mu_i = g^{-1}(\eta_i).$$

В обычных линейных моделях, основанных на нормально распределенной исследуемой переменной, the link $g(\mu_i)=\mu_i$ is usedссылкаand is called an **identity link**,,. Функция связи отображает диапазон μ_i на всю реальную , обеспечивает хорошее эмпирическое приближение и несет значимые интерпретации в реальных приложениях.

В случае логистической регрессии функция связи определяется как

$$\eta = \ln \frac{\pi}{1-\pi}.$$

Это преобразование называется **логитным** преобразованием вероятности π и $\frac{\pi}{1-\pi}$ называется **коэффициентами**. Ссылка η также называется **логарифмическими коэффициентами**. Функция этой ссылки получается следующим образом:

$$\pi = \frac{1}{1+\exp(-\eta)}$$

или $\pi\left[1+\exp(-\eta)\right]=1$

или $e^{-\eta} = \frac{1-\pi}{\pi}$

или $\mu = \ln \frac{\pi}{1-\pi}$.

Примечание: Аналогично функции logit, также другие функции, которые имеют форму, аналогичную форме логистической функции. Эти функции также могут быть преобразованы с помощью π. Существуют две такие популярные функции – пробитное преобразование и дополнительное преобразование log-log. Пробит-преобразование основано на преобразовании π с использованием кумулятивной функции распределения нормального распределения и на этом основана **пробит-регрессионная модель.**

The **Является** π $\ln\left[-\ln(1-\pi)\right]$.

Оценка максимального правдоподобия параметров:

Рассмотрим общую форму модели логистической регрессии

$$y_i = E(y_i) + \varepsilon_i$$

где $y_i's$ - независимая случайная величина Бернулли с а параметром π_i с

$$E(y_i) = \pi_i$$

$$= \frac{\exp(x_i'\beta)}{1 + \exp(x_i^i\beta)}$$

Функция плотности вероятности y_i является

$$f_i(y_i) = \pi_i^{y_i}(1 - \pi_i)^{1 - y_i}, i = 1, 2, ..., n,\ y_i = 0 \text{ or } 1.$$

Функция правдоподобия является

$$L(y_1, y_2, ..., y_n, \beta_1, \beta_2, ..., \beta_k) = L = \prod_{i=1}^{n} f_i(y_i)$$

$$= \prod_{i=1}^{n} f_i(y_i)(1 - \pi_i)^{1 - y_i}$$

$$\ln L = \sum_{i=1}^{n} \left[\ln \pi_i^{y_i} + \ln(1 - \pi_i)^{1 - y_i} \right]$$

$$= \sum_{i=1}^{n} \left[y_i \ln \pi_i + (1 - y_i) \ln(1 - \pi_i) \right]$$

$$= \sum_{i=1}^{n} \left[y_i \ln \left(\frac{\pi_i}{1 - \pi_i} \right) \right] + \sum_{i=1}^{n} \left[\ln(1 - \pi_i) \right].$$

С Тех пор , как

$$\pi_i = \frac{\exp(x_i'\beta)}{1 + \exp(x_i'\beta)},$$

$$1 - \pi_i = \frac{1}{1 + \exp(x_i'\beta)},$$

$$\frac{\pi_i}{1 - \pi_i} = \exp(x_i'\beta),$$

$$\ln \frac{\pi_i}{1 - \pi_i} = \exp x_i'\beta \quad ,$$

итак

$$\ln L = \sum_{i=1}^{n} y_i x_i'\beta - \sum_{i=1}^{n} \ln \left[1 + \exp(x_i'\beta) \right] .$$

Предположим что на каждом уровне x переменных доступны повторные наблюдения. Пусть y_i - числа 1, наблюдаемых for i^{th} observation and n_i be the количество испытаний при каждом наблюдении. Затем

$$\ln L = \sum_{i=1}^{n} y_i \pi_i + \sum_{i=1}^{n} n_i \ln(1 - \pi_i) - \sum_{i=1}^{n} y_i \ln(1 - \pi_i)$$

.

Максимального правдоподобия оценку $\hat{\beta}$ среди β получается путем численного максимизации.

Если $V(\varepsilon) = \Omega,$ тогда асимптотически

$$E(\hat{\beta}) = \beta$$
$$V(\hat{\beta}) = (X' \Omega^{-1} X)^{-1}.$$

После получения $\hat{\beta}$ линейный предиктор оценивается с помощью

$$\hat{\eta}_i = x_i' \beta.$$

Установленное значение равно

$$\hat{y}_i = \hat{\pi}_i = \frac{\exp(\hat{\eta}_i)}{1 + \exp(\hat{\eta}_i)} = \frac{1}{1 + \exp(-\hat{\eta}_i)} = \frac{1}{1 + \exp(-x_i' \hat{\beta})}.$$

Интерпретация параметров:

Чтобы понять интерпретацию связанного $\beta's$ в модели логистической регрессии, сначала рассмотрим простой случай с только одной переменной в качестве

$$\eta(x) = \beta_0 + \beta_1 x.$$

После подгонки модели, $\hat{\beta}_0$ and $\hat{\beta}_1$ получаются оценки β_0 and β_1 соответственно. Тогда подогнанный линейный предиктор в $x = x_i$ равен

$$\hat{\eta}(x_i) = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

который является логарифмическим коэффициентом при $x = x_i.$ подобранном значении при $x = x_i + 1$, равно

$$\hat{\eta}(x_i + 1) = \hat{\beta}_0 + \hat{\beta}_1 (x_i + 1)$$

скакой логарифмическойвероятностью $x = x_i + 1.$

Таким образом

$$\hat{\beta}_1 = \hat{\eta}(x_i + 1) - \hat{\eta}(x_i)$$
$$= \ln\left[\text{odds}(x_i + 1)\right] - \ln\left[\text{odds}(x_i)\right]$$
$$= \ln\left[\frac{\text{odds}(x_i + 1)}{\text{odds}(x_i)}\right]$$
$$\Rightarrow \frac{\text{odds}(x_i + 1)}{\text{odds}(x_i)} = \exp(\hat{\beta}_1).$$

Это называется **нечетным отношением,** которое представляет собой предполагаемое увеличение вероятности успеха при изменении значения объясняющей переменной на единицу.

Вслучае, когда в модели имеется более одной объясняющей переменной, тогда интерпретация $\beta_j's$ аналогична, как в случае одной explanatory variable case. Отношение шансов is exp $(\hat{\beta}_j)$ associated with explanatory variable x_j keeping otherдругойобъясняющей переменной постоянной. Это является аналогичное толкование β_j ян множественная линейная регрессионная модель.

Если объясняющей переменной является изменение в m единице измерения, тоотношение estimated increase iпредполагаемого увеличения in равноexp, „ $(m\hat{\beta}_j)$.

Проверка гипотезы:

Испытание гипотезы для параметров ян в модели логистической регрессии на основе асимптотической теории. Это тест с большой выборкой, основанный на тесте отношения правдоподобия, основанном на статистике, называемой **отклонением.**

Модель с точно *p* параметрами, которые идеально соответствуют выборочным данным, называется **насыщенной моделью.**

Статистика, которая сравнивает логарифмические вероятности of fitted and saturated models , называется **model deviance**. Это определяется как

$$\lambda(\beta) = 2\ln L(\text{saturated model}) - 2\ln L(\hat{\beta})$$

где $\ln L(\cdot)$ is the log-likelihood and $\hat{\beta}$ is the maximum likelihood estimate of β - логарифмическое правдоподобие.

В случае the logistic regression model, $y_i = 0$ π_i's are полностью неограниченными. Поэтому вероятность будет максимальной В $\pi_i = y_i$, а максимальное значение L (насыщенный модальные) - это

$$\begin{aligned} & Maximum\ L(\text{saturated model}) = 1 \\ \Rightarrow\ & \ln Maximum\, L(\text{saturated model}) = 0. \end{aligned}$$

Пусть $\hat{\beta}$ оценка максимального правдоподобия β, тогда логарифмическое правдоподобие максимально при $\beta = \hat{\beta}$, и

$$\begin{aligned} \ln L(\hat{\beta}) &= \sum_{i \exists}^{n} y_i x_i' \hat{\beta}_i - \sum_{i \exists}^{n} \ln\left[1 + \exp(x_i' \beta)\right] \\ &\geq \ln L(\text{saturated model}). \end{aligned}$$

Предполагая, что функция логистической регрессии верна, распределениестатистикиstatistic $\lambda(\beta)$ приблизительно распределяется как $\chi^2(n - p)$, когда n оно велико.

Небольшоезначение $\lambda(\beta)$, что the model is incorrect. Значениеторгового центра $\lambda(\beta)$ означает, что the model is хорошо подогнана и не уступает модели saturated. Обратите внимание, что, как правило, приталенная модель будет иметь очень небольшие количества параметров-йв насыщенном модели, учитывающей все параметры. Таким образом, на $\alpha\%$ уровне значимости.